

기말고사 대체 과제

AI × 블록체인 융합 SCI 논문 3편 분석 보고서

202035253 최지웅 | 가천대학교 컴퓨터공학과

논문 1. Deep learning-based solution for smart contract vulnerabilities detection

Tang, X. et al. | Scientific Reports 13:20106 | 2023 | DOI: 10.1038/s41598-023-47219-0

초록

본 논문은 스마트 계약 취약점 탐지에 딥러닝을 적용하는 방안을 탐구하고자 합니다. 스마트 계약은 블록체인 기술의 핵심 요소이며, 탈중앙화 애플리케이션 개발에 매우 중요합니다. 하지만 스마트 계약의 취약점은 재정적 손실과 시스템 충돌을 초래할 수 있습니다.

스마트 계약의 취약점을 탐지하기 위해 정적 분석 도구가 자주 사용되지만,

사전 정의된 규칙에 대한 의존도가 높고 의미 분석 기능이 부족하여 오탐(false positive)과 미탐(false negative)이 발생하는 경우가 많습니다.

또한, 이러한 사전 정의된 규칙은 빠르게 구식화되고 새로운 데이터에 적응하거나 일반화하는 데 실패합니다. 반면, 딥러닝 방법은 사전 정의된 탐지 규칙이 필요하지 않으며, 학습 과정에서 취약점의 특징을 학습할 수 있습니다.

본 논문에서는 딥러닝 기술을 기반으로 하는 Lightning Cat이라는 솔루션을 소개합니다.

우리는 스마트 계약의 취약점을 탐지하기 위해 OptimizedCodeBERT, Optimized-LSTM, Optimized-CNN의 세 가지 딥러닝 모델을 학습시켰습니다. 실험 결과에 따르면, 본 논문에서 제안하는 Lightning Cat 데이터셋에서 Optimized-CodeBERT 모델은 다른 방법들을 능가하여 93.53%의 f1 점수를 달성했습니다. 취약점 특징을 정확하게 추출하기 위해, 핵심적인 취약점 특징을 유지하기 위해 취약한 코드 함수의 세그먼트를 추출했습니다. CodeBERT 사전 학습 모델을 데이터 전처리에 사용함으로써, 코드의 구문과 의미를 더욱 정확하게 포착할 수 있었습니다. 제안하는 솔루션의 타당성을 입증하기 위해, 7가지 유형의 취약점이 주입된 9369개의 취약한 컨트랙트로 구성된 SolidiFI 벤치마크 데이터셋을 사용하여 성능을 평가했습니다.

서론 및 배경

스마트 컨트랙트는 한 번 블록체인에 배포되면 수정이 불가능하다. 이 특성이 강점이기도 하지만, 취약점이 있을 경우 공격자가 이를 영구적으로 악용할 수 있다는 치명적 약점이기도 하다. 실제로 2016년 The DAO 해킹(6,000만 달러), 2021년 Poly Network 해킹(6억 달러)이 모두 스마트 컨트랙트 취약점에서 비롯되었다.

기존 Slither, Mythril 같은 정적 분석 도구들은 미리 정의된 규칙으로만 패턴을 찾기 때문에 새로운 취약점에 대응하지 못하고 오탐률도 높다. 딥러닝을 활용한 선행 연구들도 컨트랙트 전체 코드를 그대로 입력해 학습 노이즈가 많다는 한계가 있었다.

기술적 본문

이 논문의 핵심 아이디어는 **취약점과 직접 관련된 함수 코드만 추출하여 모델에 입력**하는 것이다. 500줄짜리 컨트랙트에서 취약점이 있는 30줄짜리 함수만 뽑아 학습하는 방식으로, 불필요한 노이즈를 크게 줄였다.

탐지 대상은 Re-entrancy(재진입 공격), Timestamp Dependency, Unhandled Exceptions, tx.origin 남용의 4가지 주요 취약점이다. 세 모델 중 핵심인 **Optimized-CodeBERT**는 Microsoft가 개발한 코드 전용 트랜스포머 모델로, 코드 토큰 간의 관계를 어텐션 메커니즘으로 파악해 취약점을 분류한다.

31,909개 코드로 훈련하고 SolidiFI-benchmark(5,434개) 기준으로 평가한 결과, Optimized-CodeBERT가 F1 93.53%, 재현율 93.55%를 기록하며 기존 Slither 대비 재현율 약 12%p 향상을 달성하였다.

결론

AI가 블록체인의 코드 수준 취약점을 기존 도구보다 훨씬 정확하게 찾아낼 수 있음을 보여준 연구다. 현재는 이더리움 Solidity 언어와 사전 정의된 4가지 취약점 유형에 한정되어 있으며, 향후 다양한 블록체인 언어와 새로운 취약점 유형으로의 확장이 과제로 남아 있다.

논문 1 분석 및 시사점

이 논문에서 진짜 중요한 아이디어는 모델 자체가 아니다. "전체 코드가 아닌 취약점 함수만 떼어내서 학습시킨다"는 전처리 전략이다. 보통 딥러닝 연구라고 하면 새로운 아키텍처나 학습 기법을 내세우는데, 이 논문은 데이터를 어떻게 잘라서 넣느냐가 성능을 결정한다는 걸 보여준다. 어찌 보면 당연한 말인데, 이걸 실제로 적용해서 12%p 성능 향상을 이끌어냈다는 게 의미 있다.

그런데 여기서 한 가지 걸리는 게 있다. 이 모델이 탐지할 수 있는 취약점이 딱 4가지로 정해져 있다는 것이다. Re-entrancy, Timestamp Dependency, 이런 것들은 이미 업계가 다 알고 있는 유형이다. 공격자 입장에서는 굳이 알려진 방식을 쓸 이유가 없다. 새로운 패턴을 만들면 그만이다. 결국 이 모델은 "이미 알려진 공격만 막는 시스템"이 되는 것이고, 이건 기존 정적 분석 도구들이 가졌던 한계와 본질적으로 같다.

다만 현실에서 당장 써먹을 수 있는 분야는 분명히 있다. 스마트 컨트랙트를 배포하기 전에 자동으로 1차 검수하는 파이프라인이다. 지금 이 과정은 보안 전문가들이 수작업으로 하고, 비용도 비싸고 시간도 오래 걸린다. Lightning Cat 같은 시스템이 그 1차 필터링을 맡아준다면, 최소한 알려진 취약점은 배포 전에 걸러낼 수 있다. 완벽한 해결책은 아니지만, 없는 것보다는 훨씬 낫다.

논문 2. Defending Against Poisoning Attacks in Federated Learning With Blockchain

Dong, N. et al. | IEEE Transactions on Artificial Intelligence, Vol. 5, No. 7 | 2024 | DOI: 10.1109/TAI.2024.3376651

초록

요약—딥러닝 시대에 연합 학습(FL)은

다수의 기관 데이터 소유자 또는 클라이언트가 데이터 개인정보를 침해하지 않고 머신러닝 모델을 공동으로 학습할 수 있도록 하는 유망한 접근 방식입니다.

그러나 기존의 대부분의 FL 접근 방식은 전역 모델 집계를 위해 중앙 집중식 서버에 의존하므로 단일 장애 지점이 발생합니다.

이로 인해 시스템은 부정직한 클라이언트를 처리할 때 악의적인 공격에 취약해집니다.

본 연구에서는 블록체인 및 분산 원장 기술을 기반으로 하는 안전하고 신뢰할 수 있는 FL 시스템을 제안하여 이 문제를 해결합니다. 본 시스템은 온체인 스마트 계약으로 구동되는 P2P 투표 메커니즘과 보상 및 슬래시 메커니즘을 통합하여 악의적인 행위를 탐지하고 억제합니다. 이론적 및 실증적 분석을 통해 제안된 접근 방식의 효과를 입증하고,

본 프레임워크가 악의적인 클라이언트 측 행위에 대해 강건함을 보여줍니다.

영향력—FL은 사용자의 개인정보를 보호하면서 다중 사이트 데이터를 활용할 수 있는 유망한 솔루션입니다. 블록체인과 연합 학습(FL)을 통합하여 글로벌 모델 집계를 분산화하는 데 성공했음에도 불구하고,

연합 시나리오에서 악의적인 의도를 가진 클라이언트로부터 이러한 통합을 보호하는 방법은 여전히 불분명합니다.

본 논문은 이 문제에 대한 최초의 정식화를 제시하며,

제안된 지분 기반 집계 메커니즘은 악의적인 행위를 탐지하는 데 있어 견고성을 보여줍니다.

본 연구 결과는 연합 학습에 새로운 연구 방향을 제시할 뿐만 아니라,

금융 및 의료와 같은 다양한 응용 분야에도 도움이 될 수 있습니다.

색인어—블록체인, 딥러닝, 연합 학습(FL), 신뢰할 수 있는 머신러닝

서론 및 배경

연합학습에서 참여자들은 자신의 로컬 데이터로 모델을 학습한 뒤 모델 가중치만 중앙 서버에 업로드하고, 서버는 이를 평균 내어(FedAVG) 글로벌 모델을 만든다. 데이터 자체가 이동하지 않으므로 의료, 금융 등 민감 데이터 분야에서 특히 유용하다.

문제는 포이즈닝 공격이다. 악의적 참여자가 의도적으로 잘못된 데이터로 학습하거나 모델 가중치 자체를 조작하면 글로벌 모델 전체가 오염된다. 기존 방어 방법들은 중앙 서버에 의존하거나 모델 성능 자체를 희생해야 하는 trade-off가 있었다.

기술적 본문

이 논문의 핵심은 블록체인의 "정직하면 보상, 부정직하면 손실" 원리를 연합학습에 이식하는 것이다.

참여자(Proposer(제안자)와 Voter(투표자)로 나뉜다. Proposer는 로컬 학습 결과를 블록체인에 업로드하며 일정 지분(토큰)을 예치한다. Voter는 해당 업데이트를 자신의 검증 데이터로 평가한 뒤 수락 또는 거부 투표를 한다. 다수결로 수락된 업데이트만 집계 포함되며, 다수결에서 이긴 편은 진 편 지분을 보상으로 받고 진 편은 지분을 잃는다. 이 모든 과정을 이더리움 스마트 컨트랙트가 자동으로 처리한다. 논문은 수학적 증명을 통해 합리적인 참여자라면 악의적으로 투표하는 것이 항상 손해임을 보였다.

실험 결과, 방어 없이 악의적 참여자 40%가 있는 경우 AUC가 0.709까지 폭락하는 반면, 제안 방법은 같은 조건에서 0.955를 유지하며 공격이 없는 이상적 환경(0.969)에 거의 근접하였다.

결론

블록체인이 단순한 데이터 저장 수단이 아니라, AI 학습 환경의 신뢰 기반 자체를 구축하는 도구로 사용될 수 있음을 보여준다. 다만 블록체인 트랜잭션 비용(가스비)과 처리 지연이 실용화의 과제로 남아 있다.

논문 2 분석 및 시사점

이 논문에서 가장 흥미로웠던 부분은 보안 문제를 기술적으로 막는 게 아니라, 경제적으로 설계했다는 점이다. "악의적으로 행동하면 손해가 된다"는 구조를 만들어버리면, 공격자를 탐지하거나 차단할 필요 자체가 줄어든다. 스스로 공격을 포기하게 만드는 것이다. 생각해보면 이건 블록체인이 원래부터 가지고 있는 인센티브 설계 철학을 연합학습에 그대로 가져온 것이다.

하지만 한 가지 전제가 있다. 이 메커니즘은 참여자들이 합리적으로 행동한다는 가정 위에 서 있다. 경제적 손실이 두렵기 때문에 정직하게 행동한다는 논리인데, 이게 항상 성립하지는 않는다. 국가 차원의 공격자라면 어떨까? 토큰 몇 개를 잃는 것쯤은 아무 문제도 아니고, 모델 자체를 오염시키는 것이 목적이라면 이 인센티브 구조가 전혀 통하지 않는다. 이전 보고서에서도 다뤘지만, 러시아나 북한 같은 국가들이 AI를 이용해 블록체인 시스템을 공격하는 사례가 이미 나오고 있다. 경제적 합리성이 기본 가정인 이 시스템은 그런 공격에는 사실상 무방비다.

그래도 이 논문이 제안하는 모델이 빛을 발할 수 있는 곳은 있다. 의료 AI처럼 여러 기관이 협력해서 모델을 공동 학습해야 하는데, 참여 기관 중 일부가 데이터를 조작하거나 경쟁 목적으로 모델을 방해할 가능성이 있는 환경이다. 이 경우 참여 기관들은 모두 국가 법인이고, 경제적 인센티브에 반응하는 합리적 기관들이다. 블록체인의 경제 설계가 제대로 작동할 수 있는 조건이다.

논문 3. Blockchain security enhancement an approach towards hybrid consensus algorithms and machine learning techniques

Venkatesan, K. & Rahayu, S.B. | Scientific Reports 14:1149 | 2024 | DOI: 10.1038/s41598-024-51578-7

초록

본 논문에서는 블록체인 네트워크의 문제점과 취약점을 해결하기 위해 머신러닝(ML) 기법을 결합한 하이브리드 합의 알고리즘을 제안합니다. 합의 프로토콜은 분산 시스템에서 신청자 간의 합의를 보장하는 것을 어렵게 만듭니다. 그러나 기존 메커니즘은 사이버 공격에 매우 취약합니다. 이전 연구들은 사이버 공격의 영향을 광범위하게 탐구하고 효과적인 예방 조치의 필요성을 강조했습니다. 본 연구는 제안된 하이브리드 합의 알고리즘에 ML 기법을 통합하고 사이버 공격 예측, 이상 탐지 및 특징 추출 측면에서의 이점을 제시합니다. 본 연구에서 제안하는 하이브리드 접근 방식은 제안된 합의 프로토콜의 보안, 신뢰성 및 견고성을 활용하고 최적화합니다. 또한, 본 연구는 위임 지분 증명 작업(DPoSW), 지분 및 작업 증명(PoSW), CASBFT 증명(PoCASBFT), 위임 비잔틴 지분 증명(DBPoS)과 같은 다양한 ML 기법을 하이브리드 합의 알고리즘과 결합하여 보안 강화 및 합의 프로토콜에서의 지능형 의사 결정을 탐구합니다. 본 연구에서는 ProximaX 블록체인 플랫폼을 활용한 분산 네트워크 환경에서 제안된 방법론의 효과를 입증합니다. 본 연구는 제안된 연구 프레임워크가 보안을 유지하면서 에너지 효율적이고 동적 환경에 적응하는 메커니즘임을 보여줍니다. 또한, 개인정보 보호 기능, 견고한 합의 메커니즘, 그리고 머신러닝(ML) 접근 방식을 통합하여 보안 위협을 탐지하고 방지합니다. 나아가, 이러한 ML 기반 하이브리드 합의 모델의 실제 구현은 확장성, 지연 시간, 처리량, 자원 요구 사항, 그리고 잠재적인 적대적 공격과 같은 중요한 과제에 직면해 있습니다.

실제 시나리오에서 블록체인 네트워크의 성공적인 구현을 위해서는 이러한 과제들을 반드시 해결해야 합니다.

서론 및 배경

51% 공격이란 공격자가 네트워크 연산 능력의 과반을 장악해 블록체인 데이터를 조작하는 공격이다. 이미 처리된 거래를 취소(이중 지불)하거나 블록 보상을 독점하는 방식으로 악용된다.

현재 PoW, PoS, DPoS, PBFT 등 각 합의 알고리즘은 뚜렷한 장점을 가지지만 동시에 고유한 취약점도 가진다. 서로 다른 알고리즘의 강점을 결합하면 각각의 약점을 상쇄할 수 있다는 것이 이 논문의 출발점이다.

기술적 본문

4가지 하이브리드 합의 알고리즘의 핵심 구조는 다음과 같다. **DPoSW**는 DPoS로 트랜잭션을 검증하고 PoW로 블록을 생성한다. 51% 공격을 위해 지분 과반과 해시 파워 과반을 동시에 장악해야 하므로 공격 비용이 기하급수적으로 올라간다. **PoSW**는 DPoS의 대표자 선출 대신 무작위 PoS 선택을 사용해 더 탈중앙화된 버전이다. **PoCASBFT**는 Casper PoS로 체크포인트를 관리하고 PBFT로 각 블록을 즉각 확정하여 포크 자체를 막는다. **DBPoS**는 DPoS로 선출된 소수 검증자들이 PBFT로 합의하는 구조로, 기업·컨소시엄 블록체인에 적합하다.

하이브리드 합의로 대응하기 어려운 은밀하고 점진적인 공격에는 머신러닝 기반 이상 탐지를 병행한다. 트랜잭션 패턴, 네트워크 연결 구조, 참여자 평판 등 다양한 특성을 추출하여 실시간으로 분석한다. 지도학습(SVM, 랜덤포레스트)은 알려진 공격 패턴을 정확히 분류하고, 비지도학습(DBSCAN, Isolation Forest)은 새로운 유형의 이상 행동을 탐지한다. GAN은 희귀한 공격 시나리오 데이터를 생성해 학습 데이터 부족 문제를 보완한다.

결론

블록체인과 AI를 각각 독립적으로 개선하는 것을 넘어, 두 기술을 하나의 보안 아키텍처 안에 통합하는 청사진을 제시한다. 하이브리드 합의가 구조적 방어를 담당하고 ML이 동적 위협 탐지를 담당하는 이중 방어 체계다. 실험 규모가 ProximaX 플랫폼으로 제한되어 대규모 공개 네트워크에서의 검증이 과제로 남아 있다.

논문 3 분석 및 시사점

이 논문은 솔직히 말하면, 특정 기술 하나를 깊게 파는 논문이라기보다는 방향성 제안에 가깝다. "이런 하이브리드 합의 알고리즘들이 있고, ML을 이렇게 결합할 수 있다"는 식의 체계적인 분류와 조망이 이 논문의 핵심 기여다. 그래서 실험 규모가 작고 정량적 비교가 부족하다는 아쉬움은 있지만, 연구자나 설계자 입장에서는 방향을 잡는 데 상당히 유용한 자료다.

하지만 이 논문의 접근이 이더리움이나 비트코인 같은 대규모 퍼블릭 블록체인에 적용되기까지는 시간이 꽤 걸릴 것 같다. 하이브리드 합의 알고리즘은 기존 네트워크 전체가 합의 방식을 바꿔야 한다. 수만 개의 노드가 지금 사용하는 방식을 버리고 새 방식으로 이동하는 것, 그게 얼마나 어려운지는 이더리움의 PoW → PoS 전환에 몇 년이 걸린 걸 보면 알 수 있다.

반면 컨소시엄 블록체인에서는 이야기가 달라진다. 이전 보고서에서도 프라이빗·컨소시엄 블록체인이 실용성에서 훨씬 낫다고 봤는데, 이 논문의 하이브리드 합의 알고리즘들은 정확히 그 환경에 맞게 설계되어 있다. 참여자 수가 제한적이고, 신뢰할 수 있는 기관들 사이에서 돌아가는 컨소시엄 블록체인이라면 DBPoS나 PoCASBFT 같은 방식이 꽤 현실적인 선택지가 될 수 있다.

종합 결론

이전 보고서를 쓸 때 내린 결론이 "AI는 블록체인의 적"이었다. 국가 수준의 AI 해킹, 스마트 컨트랙트 취약점 자동 탐색, 51% 공격 시뮬레이션 모델 유출 같은 해킹 사례들을 보면서 AI가 블록체인을 위협하는 가장 강력한 무기가 되고 있다고 판단했다.

이번 논문 3편은 그 판단을 뒤집는 게 아니라, 뒤집어서 보여준다. AI가 블록체인의 적이 될 수 있는 것처럼, 블록체인도 AI를 보호하는 수단이 될 수 있다. 논문 1은 AI가 스마트 컨트랙트의 취약점을 공격하기 전에 먼저 찾아낼 수 있다는 걸 보여주고, 논문 2는 블록체인의 경제 설계가 AI 학습 과정 자체를 지킬 수 있다는 걸 증명하고, 논문 3은 두 기술이 결합하면 공격자가 뚫어야 할 방어선이 두 겹이 된다는 걸 제안한다.

결국 이 세 편이 공통으로 가리키는 방향은 하나다. AI와 블록체인은 서로 상대방의 약점을 채워준다는 것이다. AI 혼자로는 블록체인의 탈중앙화와 경제적 신뢰 구조를 만들 수 없고, 블록체인 혼자로는 코드 수준의 취약점 탐지와 실시간 위협 분석을 할 수 없다. 이 둘이 결합할 때 비로소 어느 한쪽이 가진 결함이 매워진다.

이전 보고서에서 프라이빗·컨소시엄 블록체인이 현실적인 해답이라고 봤는데, 이번 논문들을 읽고 나서도 그 생각은 변함없다. AI×블록체인 융합 기술이 가장 먼저, 그리고 가장 효과적으로 적용될 수 있는 환경은 여전히 참여자가 제한된 신뢰 기반 네트워크다. 의료 기관들 간의 연합학습, 방산·정부 인프라, 금융 기관 간 청산 시스템이 그것이다. 어디선가 "모든 산업을 바꿀 융합 기술"이라는 말이 나오겠지만, 그것보다는 특정 문제를 실제로 해결하는 실용적인 솔루션으로 자리잡는 쪽이 현실적이고, 그게 더 의미 있다고 생각한다.